למידת מכונה - תקציר פרויקט + קישור לפרויקט

מגישים:
איריס רביץ 320466238

קישור לגיטהאב:

https://github.com/EvgenTen/SpamDetection

השאלה שאני מתכוונת לענות עליה:
בהינתן הודעה חדשה, תוכל התוכנית לזהות אותה כהודעת ספאם או הודעה רגילה?

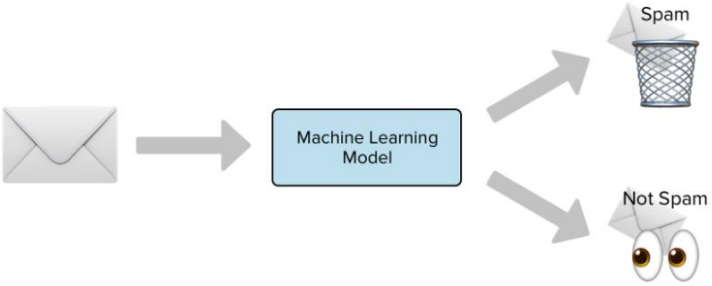

תיאור של המאגר הנבחר:

Context:

The SMS Spam Collection is a set of SMS tagged messages that have been collected for SMS Spam research. It contains one set of SMS messages in English of 5,574 messages, tagged according being ham (legitimate) or spam.

Content:
The files contain one message per line. Each line is composed by two columns: v1 contains the label (ham or spam) and v2 contains the raw text.

This corpus has been collected from free or free for research sources on the Internet.

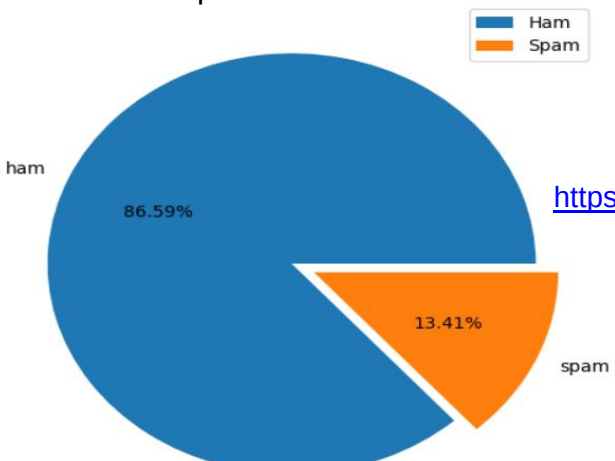

קישור למאגר המידע:

https://archive.ics.uci.edu/ml/datasets/sms+spam+collection

-Preprocess

The first step (and the harder part) was to find a way to convert the spam.csv file to data that algorithms understand.

Data Preprocessing, Feature Vector and Models Used:

1. The Dataset had two columns: 1st containing the class of data ham or spam and 2nd containing a string which is the text message.
2.All English Stopwords were imported from NLTK and were removed if found in the sentences.
3.I used a basic Count vectorizer from Sklearn library in order to tokenize and vectorize the string of text. The Count Vectorizer provides a simple way to both tokenize a collection of text documents and build a vocabulary of known words, but also to encode new documents using that vocabulary.
It can be used as follows:
a)Create an instance of the CountVectorizer class.
b)Call the fit() function in order to learn a vocabulary from document.
c)Call the transform() function on the document as needed to encode each as a vector.
An encoded vector is returned with a length of the entire vocabulary and an integer count for the number of times each word appeared in the document.
4.I got our numeric or real feature vector from string of text messages.
5.Next perform the test train split in the ratio of 70:30, we select the samples randomly.
6. I feed the X_train, X_test, y_train, y_test to different ML models namely, AdaBoost, Decision tree classifier, K-nearest neighbors, Support vector machines, (regular)MultinominalNB

The model: MultinominalNB + TfidfTransformer

```
print(ham)
```

```
      Class                                               Text  ... numClass Count
0       ham  Go until jurong point, crazy.. Available only ...  ...        0   111
1       ham                      Ok lar... Joking wif u oni...  ...        0    29
3       ham  U dun say so early hor... U c already then say...  ...        0    49
4       ham  Nah I don't think he goes to usf, he lives aro...  ...        0    61
6       ham  Even my brother is not like to speak with me. ...  ...        0    77
```

```
print(spam)
```

```
     Class                                                Text  ... numClass Count
2     spam  Free entry in 2 a wkly comp to win FA Cup fina...  ...        1   155
5     spam  FreeMsg Hey there darling it's been 3 week's n...  ...        1   148
8     spam  WINNER!! As a valued network customer you have...  ...        1   158
9     spam  Had your mobile 11 months or more? U R entitle...  ...        1   154
11    spam  SIX chances to win CASH! From 100 to 20,000 po...  ...        1   136
...    ...                                                ...  ...      ...   ...
```

```
vectorizer.fit_transform(data_read.Text)
```

```
(0, 8030) 1
(0, 4350) 1
(0, 5920) 1
(0, 2327) 1
(0, 1303) 1
(0, 5537) 1
(0, 4087) 1
(0, 1751) 1
(0, 3634) 1
```

...

```
(5570, 4161)  1
(5570, 903)   1
(5570, 1546)  1
(5571, 7756)  1
(5571, 5244)  1
(5571, 4225)  2
(5571, 7885)  1
(5571, 6505)  1
```

```
data_read.numClass
```

```
0        0
1        0
2        1
3        0
4        0
```

...

```
5567    1
5568    0
5569    0
5570    0
5571    0
```

The model: MultinominalNB + TfidfTransformer:

Data Preprocessing, Feature Vector and Models Used:

1. no change
2. no change
3. I added the TFIDF algorithm:
TFIDF, is a numerical statistic that is intended to reflect how important a word is to a document in a collection or corpus. It is often used as a weighting factor in searches of information retrieval, text mining, and user modeling. The tf–idf value increases proportionally to the number of times a word appears in the document and is offset by the number of documents in the corpus that contain the word, which helps to adjust for the fact that some words appear more frequently in general.

```
tfidf_transformer = TfidfTransformer().fit(x)
dummy_transformed = tfidf_transformer.transform(x)
print(dummy_transformed)
```

```
(5570, 1546)  0.3402048888248921
(5570, 1438)  0.1429585509124154
(5570, 1084)  0.11225268140936365
(5570, 903)   0.3247623397615813
(5571, 7885)  0.42752913176432156
(5571, 7756)  0.14849350328973984
(5571, 6505)  0.5565029307246045
(5571, 5244)  0.39009002726386227
(5571, 4225)  0.5773238083586979
```

```
(0, 8489) 0.22080132794235655
(0, 8267) 0.18238655630689804
(0, 8030) 0.22998520738984352
(0, 7645) 0.15566431601878158
(0, 5920) 0.2553151503985779
(0, 5537) 0.15618023117358304
(0, 4476) 0.2757654045621182
(0, 4350) 0.3264252905795869
```

Now, lets check IDF for '*you*', the most frequently repeated word in the message against '*hey*', a least repeated word:

```
you: 2.2548286210328206
hey: 4.907189916274442
```

As we can see, words with lower frequency are weighed higher than words with higher frequency in the dataset.

4. no change
5. I feed the X_train, X_test, y_train, y_test to ML model namely MultinominalNB.

תהליך הלמידה-

תכנות הראשוני הוא להשתמש באלגוריתמי למידת מכונה שלמדנו בשיעור. לחקור את הנתונים בעזרת המודלים:

AdaBoost, Decision tree classifier, K nearest neighbours, Support vector machines, (regular) MultinominalNB

עבודה התחלתית עם הנתונים הייתה קשה, לא ידעתי איך להאמיר טקסט לנתונים שאלגוריתם יוכל להבין. לאחר החיפושים ולימוד הנושא הצלחתי לקודד משפטים לווקטורים ומשם התקדמתי לחקירת נתונים ומציאת תוצאות ביניים. כל המודלים הראו תוצאות טובות. אז בחרתי באחת המודלים MultinominalNB, רציתי לשפר את האלגוריתם ולהגיע לתוצאות יותר מדויקות. לכן הפעלתי אלגוריתם נוסף שנקרא TFIDF. הוא נתון מספרי שנועד לשקף עד כמה מילה חשובה בטקסט. אלגוריתם שיפר את התוצאה באחוז אחד והיו גם הרצות שלא הראו שינוי. המטרה הסופית הייתה לבנות מודל חדש שממיין הודעה חדשה שנכנסת מבחוץ כמשפט ספאם או כמשפט רגיל. ולענות על השאלה שנשאלה בתחילת המחקר: בהינתן הודעה חדשה, תוכל התוכנית לזהות אותה כהודעת ספאם או הודעה רגילה? נתקעתי בבעיה נוספת, לפני כן למדתי איך לקודד קובץ שלם לווקטורים וכאן העבודה עם משפט בודד ובתוצאה לקבל וקטורים שהמודל יוכל לקרוא. לאחר החיפושים הצלחתי לממש גם את זה. והמודל היה מוכן לקלוט משפט חדש לקידוד. נשאר היה להכניס אותם למודל שמבוסס על אלגוריתמים MultinominalNB ו TFIDF ולקבל תוצאה סופית. האם הודעה החדשה ספאם או לא.

אלגוריתמים שהשתמשתי בהם:

AdaBoost*

Decision tree classifier*

K nearest neighbours*

Support vector machines*

(regular) MultinominalNB*

אלגוריתמים שהשתמשתי במודל:

MultinominalNB*

TFIDF*

תוצאות –

בכל אלגוריתם חילקתי את הדאטהסט ל70 אחוז training ו-30 אחוז testing.

באלגוריתמים **KNN** הרצתי כמה גירסאות- אחד של שכן אחד, שלושה, חמישה ושבעה.
הרצתי את האלגוריתם כמה הרצות, כל פעם שיניתי את הדאטה של test וה train, ובדקתי איזה מספר שכנים נותן את התוצאה הטובה ביותר.
התוצאות היו שונות לפי מדד הצלחה **Accuracy**, כל הווריאציות נתנו תוצאות בסביבות ה90~95 אחוזי דיוק,
במקום הראשון (תמיד) היה כאשר מספר השכנים הוא אחד, במקום השני היו שלושה שכנים ,במקום השלישי חמישה שכנים, ובמקום האחרון שבעה שכנים.
לפי המדד **F1 Score**:
That is, a good F1 score means that you have low false positives and low false negatives, so you're correctly identifying real threats and you are not disturbed by false alarms. An F1 score is considered perfect when it's 1 , while the model is a total failure when it's 0
התוצאות היו שונות, כל הווריאציות נתנו תוצאות בסביבות ה0.43 ~0.75 אחוזי דיוק,
(המודל מושלם כאשר מקבלים 1 מוחלט וכישלון מוחלט כאשר 0) במקום הראשון השכן הראשון עם דיוק הכי קרוב ל-1. במקום השני היו שלושה שכנים , במקום השלישי חמישה שכנים, ובמקום האחרון שבעה שכנים עם דיוק הכי קרוב ל-0.
אלגוריתם מראה דיוק הכי גבוה בהרצת גירסאה של שכן אחד.
תוצאות:

(מתוך הקובץ knn.py)

```
KNN1 :
Accuracy in %:
94.67703349282297


F1 Score:
0.7588075880758809
```

```
KNN3 :
Accuracy in %:
92.16507177033493


F1 Score:
0.5969230769230769
```

```
KNN5 :
Accuracy in %:
91.02870813397129


F1 Score:
0.5098039215686275
```

```
KNN7 :
Accuracy in %:
90.19138755980862


F1 Score:
0.4383561643835616
```

האלגוריתם **SVM**: תוצאה: האלגוריתם מראה דיוק גבוה בשני מדדים.

```
SVM:

Accuracy in %:
98.20574162679426


F1 Score:
0.9308755760368664
```

(מתוך הקובץ svm.py).

האלגוריתם **Adaboost**: תוצאה: האלגוריתם מראה דיוק גבוה בשני מדדים.

```
Adaboost:

Accuracy in %:
98.08612440191388


F1 Score:
0.9130434782608695
```

(מתוך הקובץ adaboost.py).

האלגוריתם **DecisionTreeClassifier** :תוצאה: האלגוריתם מראה דיוק גבוה בשני מדדים.

```
DecisionTreeClassifier:

Accuracy in %:
96.88995215311004


F1 Score:
0.8864628820960699
```

(מתוך הקובץ decisionTree.py).

האלגוריתם **MultinominalNB** :(רגיל) תוצאה: האלגוריתם מראה דיוק גבוה בשני מדדים.

```
regular_MultinomialNB:

Accuracy in %:
97.54784688995215


F1 Score:
0.9154639175257732
```

(מתוך הקובץ regularmultinominalNB.py).

האלגוריתם **TFIDF + MultinominalNB** תוצאה: האלגוריתם מראה דיוק גבוה בשני מדדים.
בהשוואה לאלגוריתם הרגיל יש שיפור קטן. (מתוך הקובץ model.py).

```
Multi-NB:

Accuracy in %:
98.74401913875597


F1 Score:
0.952808988764045
```

השוואה בין כל האלגוריתמים:
כמו כן עשיתי השוואה בין כל האלגוריתמים השונים, כדי לראות איזה אלגוריתם הוא המדויק ביותר.

במקום הראשון עם ממוצע גבוה של בערך 98.74 אחוזים- **TFIDF + MultinominalNB** .
במקום השני עם ממוצע לא רחוק ממנו של בערך 98.08-98.2 אחוזים- **SVM ו Adaboost.**
במקום השלילי והמכובד- **MultinominalNB**, עם ממוצע של בין 97.54 אחוז דיוק.
ובמקום האחרון והחביב- **DecisionTreeClassifier** עם ממוצע בין 96.88 אחוזי דיוק.
(האחוזים יכולים להשתנות מריצה לריצה בחצי אחוז לכל היותר, אבל לרוב זאת החלוקה)

טסט על הודעה חדשה-

רציתי לבחון עד כמה המודל שלי טוב גם על הודעה נכנסת חדשה.
טבלאות של מילים הכי נפוצים במאגר המחולקים לפי סוג:

```
Top 10 Spam words are :


call      346
free      217
txt       156
ur        144
u         144
mobile    123
text      121
stop      114
claim     113
reply     104
```

```
Top 10 Ham words are :


u       974
gt      318
lt      316
get     301
go      246
ok      246
got     242
ur      237
know    234
like    231
```

השתמשתי בטבלאות כדי לראות עד כמה המודל עובד נכון. למשפט החדש הכנסתי מילה מתוך הטבלאות וזה מה שקיבלתי: (מתוך הקובץ model.py).

```
Testing specific messages:


SMS1 = '[URGENT!] Your Mobile No 398174814449 was awarded a vacation'

SMS2 = 'Hello my friend, how are you?'

SMS1 is spam .. SMS2 is ham
```

1SMS- הודעת ספאם ו- 2SMS- הודעה רגילה
גם אתם יכולים לנסות את המודל ולהכניס הודעה חדשה בקונסול וללחוץ enter.

למשל:

```
please write a new sentence using words from the top spam words or regular words:
stop free
SMS1 is spam .. SMS2 is ham .. new sentence is spam
```

הכנסתי הודעה חדשה: קיבלתי שהיא ספאם. המודל עובד עם דיוק של 98 אחוז שזה די טוב.